SCROOGEVM : Accroître l'utilisation des ressources du cloud en ajustant dynamiquement la surallocation

Pierre Jacquet

Université de Lille, Inria, pierre.a.jacquet@inria.fr

Résumé

Malgré des améliorations continues, les ressources physiques du cloud restent sous-utilisées, ce qui nuit à l'efficacité de ces infrastructures au sens large. Pour pallier cette inefficacité, Les fournisseurs iaas compensent généralement les machines virtuelles (VM) surdimensionnées en proposant plus de ressources virtuelles que physiquement disponibles dans leur cluster. Cet offre se traduit en taux (e.g. vCPU / CPU).

Cependant, cette technique, connue sous le nom d'oversubscription (ou overcommitment, ou overbooking) peut dégrader les performances applicatives lorsqu'un ratio d'oversubscription défini statiquement entraîne une contention des ressources demandées par les différentes VMs hébergées.

Par conséquent, au lieu de déterminer un ratio statique à l'échelle du cluster, cet article propose d'estimer dynamiquement le taux d'oversubscription optimal par serveur et type de ressources, tout en préservant les objectifs de performances. Maintenir les performances inchangées permet à notre contribution d'être adoptée de manière plus réaliste dans une infrastructures IaaS. En particulier, pour éviter les pénalités dues aux migrations de VM, le montant des ex-ressources virtuelles posées et, par conséquent, la ressource associée les ratios d'oversubscription, ne devraient être qu'augmentés.

Nous relevons ce défi en introduisant ScroogeVM, une approche précautionneuse qui tire parti de la détection de stabilité des serveurs pour augmenter prudemment le taux d'oversubscription associé.

Basé sur des datasets rendues disponibles par des Cloud Providers, nous étudions d'abord l'impact des taux d'oversubscription pour différentes fenêtres d'agrégation. Ensuite, nous proposons une méthodologie pour estimer la confiance dans un centile chois, en utilisant son évolution précédemment observée.

Nous montrons que la combinaisons appropriées de durée d'aggrégation et de percentile permet d'améliorer les stratégies d'oversubscription communément adoptées, sans imposer de migrations de VM et sans entraver les performances applicatives.

Mots-clés: cloud, iaas, surallocation